

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA ĐIỆN – ĐIỆN TỬ
BỘ MÔN VIỄN THÔNG



ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC
TRUY XUẤT VIDEO THÔNG QUA NỀN TẢNG WEB

SVTH: Phan Anh Minh

MSSV: 2111757

GVHD: TS. Võ Tuấn Kiệt

TP. HỒ CHÍ MINH, THÁNG 4 NĂM 2025

Số: ____ /BKĐT

Khoa: Điện – Điện tử

Bộ Môn: Viễn thông

NHIỆM VỤ LUẬN VĂN TỐT NGHIỆP

1. **Họ và tên:** Phan Anh Minh **MSSV:** 2111757
2. **Ngành Điện – Điện tử** **Chuyên ngành:** Kỹ thuật Điện tử - Truyền thông
3. **Đề tài:** *Truy xuất video thông qua nền tảng WEB*
4. **Nhiệm vụ:**
 - Tìm hiểu các phương pháp truy xuất video hiện đại và hệ thống đánh giá VBS.
 - Ứng dụng các mô hình như BEiT3, YOLOv8, DeepSolo, PARSeq để xử lý văn bản và đối tượng trong ảnh/video.
 - Xây dựng hệ thống web hỗ trợ truy vấn video theo văn bản, đối tượng, OCR và truy xuất theo thời gian và đánh giá hiệu suất.
5. **Ngày giao nhiệm vụ LVTN:** 15/1/2025.
6. **Ngày hoàn thành nhiệm vụ:** 15/4/2025.
7. **Họ và tên người hướng dẫn:** **Phần hướng dẫn**
TS. Võ Tuấn Kiệt 100%

Nội dung và yêu cầu luận văn tốt nghiệp đã được thông qua Bộ Môn.

TP.HCM, ngày 20 tháng 4 năm 2025

CHỦ NHIỆM BỘ MÔN NGƯỜI HƯỚNG DẪN CHÍNH

TS. Hà Hoàng Kha

TS. Võ Tuấn Kiệt

PHẦN DÀNH CHO KHOA, BỘ MÔN:

- Người duyệt (chấm sơ bộ): ____
- Đơn vị: ____
- Ngày bảo vệ : ____
- Điểm tổng kết: ____
- Nơi lưu trữ luận văn tốt nghiệp: ____

LỜI CẢM ƠN

Trước hết, em xin bày tỏ lòng biết ơn chân thành và sâu sắc đến quý thầy cô Trường Đại học Bách Khoa – Đại học Quốc gia Thành phố Hồ Chí Minh, đặc biệt là quý thầy cô Khoa Điện – Điện tử và Bộ môn Viễn thông. Nhờ sự tận tụy và tâm huyết trong công tác giảng dạy, quý thầy cô không chỉ truyền đạt cho em nền tảng kiến thức vững chắc mà còn định hướng tư duy và hun đúc niềm đam mê nghiên cứu khoa học trong suốt quá trình học tập.

Em xin gửi lời cảm ơn đặc biệt đến thầy TS. Võ Tuấn Kiệt – người thầy hướng dẫn đã đồng hành và hỗ trợ em trong suốt quá trình thực hiện đồ án tốt nghiệp. Em luôn trân trọng sự tận tâm, nghiêm khắc nhưng đầy nhiệt huyết của thầy trong từng buổi góp ý, từng lời chỉ dẫn. Chính nhờ những định hướng quý báu đó, em đã vượt qua nhiều khó khăn và hoàn thành tốt đồ án này.

Một lần nữa, em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày 20 tháng 4 năm 2025

TÓM TẮT LUẬN VĂN

Trong bối cảnh dữ liệu video ngày càng gia tăng mạnh mẽ, nhu cầu tìm kiếm và truy xuất thông tin từ nội dung video trở nên cấp thiết trong nhiều lĩnh vực như giám sát an ninh, truyền thông, giáo dục và lưu trữ tư liệu. Luận văn này trình bày quá trình xây dựng một hệ thống truy xuất video đa phương thức trên nền tảng web, cho phép người dùng tìm kiếm các đoạn video liên quan dựa trên truy vấn ngôn ngữ tự nhiên, đối tượng hoặc văn bản trong ảnh.

Hệ thống đề xuất áp dụng các mô hình học sâu tiên tiến gồm: BEiT3 để mã hóa truy vấn văn bản thành vector ngữ nghĩa, YOLOv8 để phát hiện đối tượng, DeepSolo kết hợp với PARSeq để nhận diện văn bản trong ảnh, và FAISS để thực hiện tìm kiếm gần đúng trên không gian vector. Ngoài ra, hệ thống còn tích hợp Atlas Search của MongoDB để thực hiện tìm kiếm mờ (fuzzy search) trên các đoạn văn bản được trích xuất.

Hệ thống được thử nghiệm trên tập dữ liệu từ cuộc thi AI Challenge 2024 với nhiều dạng truy vấn đa dạng. Kết quả đạt được cho thấy khả năng truy xuất chính xác, phản hồi nhanh và hỗ trợ tốt cho các truy vấn có tính ngữ nghĩa hoặc chứa yếu tố trực quan như biển hiệu, vật thể, hành động. Luận văn không chỉ góp phần nghiên cứu ứng dụng các mô hình đa phương thức trong truy xuất thông tin, mà còn đề xuất một hướng triển khai thực tiễn hiệu quả cho các hệ thống tìm kiếm video thông minh.

MỤC LỤC

DANH MỤC CÁC TỪ VIẾT TẮT	x
Chương 1. GIỚI THIỆU ĐỀ TÀI	1
1.1 Tổng quan đề tài nghiên cứu	1
1.2 Mục tiêu nghiên cứu	2
1.3 Nhiệm vụ của luận văn	2
1.4 Phương pháp thực hiện	3
Chương 2. CƠ SỞ LÝ THUYẾT	5
2.1 Mô hình CLIP và các mô hình tương tự	5
2.1.1 Nguyên lý hoạt động của CLIP	5
2.1.2 Lợi thế và ứng dụng của CLIP	6
2.1.3 Hạn chế của CLIP	7
2.1.4 Vai trò trong nghiên cứu hiện tại	7
2.1.5 Mô hình BEIT3	8
2.2 Phát hiện đối tượng bằng YOLOv8 và lưu trữ thông tin phục vụ truy hồi	10
2.2.1 Tổng quan về phát hiện đối tượng (Object Detection) . . .	10
2.2.2 YOLOv8: Phương pháp phát hiện nhanh và chính xác . . .	11
2.2.3 Lưu trữ thông tin phát hiện phục vụ truy hồi nội dung . . .	12
2.2.4 Ứng dụng trong hệ thống truy hồi nội dung	13
2.3 Nhận dạng ký tự quang học (OCR) và ứng dụng trong truy xuất thông tin	13
2.3.1 Tổng quan về OCR trong ảnh và video	13

2.3.2	Phát hiện vùng văn bản với DeepSolo	14
2.3.3	Nhận dạng ký tự tiếng Việt với PARSeq	14
2.3.4	Truy xuất nội dung dựa trên kết quả OCR	15
2.3.5	Đánh giá hiệu suất của hệ thống OCR tích hợp DeepSolo và PARSeq	15
2.4	Index-Based Nearest Neighbor Search	16
2.5	Database và faiss	17
2.5.1	Vector database là gì?	17
2.5.2	MongoDB là gì?	18
2.5.3	Faiss là gì?	18
2.5.4	Kiến trúc của TransNet V2	19
2.5.5	Dữ liệu huấn luyện	20
2.5.6	Hiệu suất và ứng dụng	20
Chương 3. NỘI DUNG THỰC HIỆN		21
3.1	Yêu cầu đối với hệ thống	21
3.2	Các chế độ truy xuất trong hệ thống VBS-Web Server	21
3.3	Các chế độ truy xuất trong hệ thống VBS-Web Server	22
3.4	Giai đoạn xử lý và lưu trữ thông tin	23
3.5	Giai đoạn truy vấn và truy xuất thông tin	24
3.6	Giải thuật chi tiết và giải thích	25
3.6.1	Tách khung hình chính từ video	25
3.6.2	Mã hóa khung hình bằng BEIT3	26
3.6.3	Lưu trữ embedding vào FAISS	27
3.6.4	Object Detection	28
3.6.5	OCR	29

3.7	Lưu trữ các trường trong MongoDB	30
3.7.1	Phân tích kiến trúc kỹ thuật của VBS-Web Server	31
3.8	Giao diện người dùng và các phương pháp truy xuất hỗ trợ	32
3.8.1	Thiết kế giao diện người dùng	32
3.8.2	Tìm kiếm ngữ nghĩa dựa trên vector (Semantic Search)	33
3.8.3	Tìm kiếm văn bản trong ảnh (OCR-Based Search)	34
3.8.4	Tìm kiếm dựa trên phát hiện đối tượng (Object-Based Search)	35
3.8.5	Tìm kiếm theo khung hình lân cận (nearest neighbor Search)	36
3.8.6	Tổng hợp các phương thức truy vấn	38
Chương 4. KẾT QUẢ THỰC HIỆN		40
4.1	Thực nghiệm và Cách Đánh Giá	40
4.2	Một số mẫu câu ví dụ trong cuộc thi	43
4.2.1	Truy vấn với mô tả đơn giản, cụ thể	43
4.2.2	Truy xuất với nhiều thông tin nhiễu do từ khoá chồng chéo	43
4.2.3	Truy vấn với cách diễn đạt khác so với truy vấn ban đầu	47
4.2.4	Truy vấn dài với chuỗi diễn tiến theo thời gian	47
4.2.5	Truy vấn bằng OCR khi thiếu mô tả rõ ràng	51
Chương 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN		53
4.3	Kết luận chung	53
4.4	Hạn chế	54
4.5	Hướng phát triển	55

DANH MỤC HÌNH ẢNH

2.1	Nguyên lý hoạt động của huấn luyện CLIP	6
2.2	minh họa mối tương quan giữa văn bản và hình ảnh trong mô hình CLIP	7
2.3	BEIT-3 có thể được chuyển giao cho nhiều nhiệm vụ hạ nguồn về thị giác và thị giác-ngôn ngữ. Với Multiway Transformer chung, chúng ta có thể tái sử dụng mô hình dưới dạng (a)(b) các bộ mã hóa thị giác hoặc ngôn ngữ; (c) các bộ mã hóa kết hợp mã hóa đồng thời các cặp hình ảnh-văn bản để tạo ra sự tương tác sâu sắc; (d) các bộ mã hóa đôi mã hóa riêng biệt các phương thức cho việc truy xuất hiệu quả; (e) học theo dạng sequence-to-sequence cho việc sinh văn bản từ hình ảnh.	9
2.4	Hiệu suất của BEIT3	10
3.5	Pipeline xử lý và lưu trữ thông tin từ video	23
3.6	Các cơ chế tìm kiếm trong hệ thống truy xuất VBS-Web	24
3.7	Lựa chọn khung hình chính từ mỗi cảnh	25
3.8	Minh họa sau khi thực hiện TransNet V2 để lọc khung hình	26
3.9	Cấu trúc file JSON lưu trữ vector embedding	27
3.10	Giao diện chính của hệ thống khi truy vấn bằng văn bản	33
3.11	Chi tiết một khung hình sau khi chọn truy vấn	33
3.12	Truy xuất khi sử dụng tiếng việt	34
3.13	Minh họa truy vấn tìm kiếm văn bản trong ảnh	34
3.14	Tìm kiếm khi khung hình chứa toàn bộ đối tượng trong truy vấn (logic AND)	36
3.15	Tìm kiếm khi khung hình chứa ít nhất một đối tượng trong truy vấn (logic OR)	36
3.16	Tìm kiếm theo khung hình lân cận	37

4.17	Điểm truy vấn trung bình trong mỗi pack	42
4.18	Kết quả truy xuất cho truy vấn mô tả cảnh chụp ảnh bên bảng nhiệt độ ngoài trời	44
4.19	So sánh các khung hình truy xuất theo từng mức độ phù hợp với truy vấn gốc	46
4.20	Kết quả truy xuất từ truy vấn “có một con số trên bầu trời” – con số “27” được biểu diễn bởi dàn drone	48
4.21	Khung hình kế cận tìm được qua chức năng <i>Search Nearest</i> , cho thấy hình ảnh gấu trúc được tạo bởi dàn drone	49
4.22	Quy trình truy xuất khung hình trong thời gian dài	50
4.23	Tính năng OCR-Based Search với truy vấn từ khoá “termi”	51
4.24	Hệ thống trả về frame có dòng chữ “termi” đúng vị trí cần truy xuất	52

DANH MỤC BẢNG BIỂU

0.1	Bảng viết tắt các thuật ngữ tiếng Anh - tiếng Việt	x
3.2	Tổng hợp các phương thức truy xuất trong hệ thống	38
3.3	So sánh các phương thức truy xuất trong hệ thống	39
4.4	Kết quả vòng sơ tuyển cuộc thi AI Challenge TP. Hồ Chí Minh . .	42

DANH MỤC CÁC TỪ VIẾT TẮT

Viết tắt	Tiếng Anh	Tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
TBVR	Text-Based Video Retrieval	Truy xuất video dựa trên văn bản
CBVR	Content-Based Video Retrieval	Truy xuất video dựa trên nội dung
CLIP	Contrastive Language–Image Pre-training	Tiền huấn luyện tương phản ngôn ngữ–hình ảnh
BEIT3	Bidirectional Encoder Representation from Image Transformers 3	Mô hình BEIT phiên bản 3
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
VBS	Video Browser Showdown	Cuộc thi đánh giá công cụ tìm kiếm video tương tác
HTV	Ho Chi Minh City Television	Đài Truyền hình TP. Hồ Chí Minh
JSON	JavaScript Object Notation	Định dạng dữ liệu JSON
FAISS	Facebook AI Similarity Search	Thư viện tìm kiếm tương đồng vector của Facebook AI
OCR	Optical Character Recognition	Nhận dạng ký tự quang học

Bảng 0.1 Bảng viết tắt các thuật ngữ tiếng Anh - tiếng Việt

Chương 1. GIỚI THIỆU ĐỀ TÀI

1.1 Tổng quan đề tài nghiên cứu

Sự phát triển vượt bậc của công nghệ và Internet đã dẫn đến sự bùng nổ dữ liệu video, biến truy xuất video (*video retrieval*) thành một lĩnh vực nghiên cứu quan trọng. Các ứng dụng của truy xuất video hiện diện trong nhiều lĩnh vực như giải trí, giáo dục, quảng cáo, giám sát an ninh, y tế và phân tích hành vi người dùng. Với số lượng video khổng lồ và tính phức tạp của nội dung video, việc tìm kiếm thông tin nhanh chóng và chính xác từ các kho lưu trữ trở thành một thách thức lớn.

Video là dạng dữ liệu đa phương tiện chứa đựng thông tin hình ảnh, âm thanh và văn bản (nếu có), với đặc điểm không gian và thời gian liên tục. Điều này khiến truy xuất video đối mặt với nhiều thách thức, bao gồm:

- **Khoảng cách ngữ nghĩa:** Nội dung video thường không trực tiếp biểu thị ý định tìm kiếm của người dùng, tạo ra một khoảng cách ngữ nghĩa cần được giải quyết.
- **Đa dạng dữ liệu:** Video có sự biến đổi lớn về ngữ cảnh, nội dung, và định dạng, làm tăng độ phức tạp khi xây dựng hệ thống truy xuất.
- **Kích thước dữ liệu:** Với sự gia tăng không ngừng về số lượng và độ dài video, việc xử lý hiệu quả và nhanh chóng là một yêu cầu thiết yếu.

Các phương pháp hiện đại trong truy xuất video đã phát triển để giải quyết các thách thức này. Trong đó, hai hướng tiếp cận chính là:

- **Truy xuất dựa trên nội dung (Content-Based Video Retrieval - CBVR):** Sử dụng các đặc trưng hình ảnh, chuyển động hoặc âm thanh để tìm kiếm video.
- **Truy xuất dựa trên văn bản (Text-Based Video Retrieval - TBVR):** Sử dụng các mô tả ngôn ngữ tự nhiên để tìm kiếm video, nhờ sự phát triển của các mô hình học sâu và xử lý ngôn ngữ tự nhiên (NLP).

Trong bối cảnh đó, cuộc thi **Video Browser Showdown (VBS)** đóng vai trò như một nền tảng đánh giá thực tiễn và thúc đẩy nghiên cứu trong lĩnh vực truy xuất video. VBS không chỉ kiểm tra hiệu năng của các hệ thống mà còn nhấn mạnh vào khả năng sử dụng đối với người dùng thông thường. Các truy vấn được thiết kế đa dạng, bao gồm *Tìm kiếm mục tiêu* (Known-Item Search) và *Tìm kiếm video ngẫu nhiên* (Ad-hoc Video Search), nhằm kiểm tra toàn diện khả năng tìm kiếm nhanh chóng, chính xác và đa dạng của các hệ thống [1].

1.2 Mục tiêu nghiên cứu

Nghiên cứu này hướng đến các mục tiêu chính sau:

- **Phát triển các hệ thống truy xuất video hiệu quả:** Nghiên cứu và cải tiến các thuật toán truy xuất video, đặc biệt trong việc thu hẹp khoảng cách ngữ nghĩa giữa nội dung video và ý định tìm kiếm của người dùng.
- **Tăng cường truy xuất dựa trên văn bản:** Tập trung vào truy xuất video thông qua các mô tả ngôn ngữ tự nhiên, một phương thức ngày càng phổ biến và thân thiện với người dùng.

Nghiên cứu không chỉ đóng góp vào việc cải thiện các thuật toán và mô hình truy xuất video hiện tại mà còn tạo ra những phương pháp mới có khả năng ứng dụng cao trong thực tiễn. Qua đó, nghiên cứu này kỳ vọng thúc đẩy sự phát triển của lĩnh vực truy xuất video trong bối cảnh dữ liệu lớn ngày nay.

1.3 Nhiệm vụ của luận văn

Để hoàn thiện hệ thống truy xuất video nêu trên, luận văn xác định các nhiệm vụ chính cần thực hiện như sau:

- **Nhiệm vụ 1:** Tìm hiểu tổng quan lý thuyết về lĩnh vực truy xuất video (video retrieval), bao gồm các phương pháp CBVR, TBVR và hệ thống đánh giá thực nghiệm như Video Browser Showdown (VBS).
- **Nhiệm vụ 2:** Nghiên cứu và ứng dụng các mô hình hiện đại bao gồm:
 - Mô hình phát hiện đối tượng: YOLOv8.

- Mô hình vision-language: BEiT3 (hoặc CLIP, BLIP).
 - Mô hình OCR: DeepSolo và PARSeq cho nhận diện văn bản trong ảnh.
 - Công nghệ lưu trữ và truy vấn dữ liệu: MongoDB, FAISS, và thuật toán tìm kiếm hàng xóm gần nhất (Nearest Neighbor Search).
- **Nhiệm vụ 3:** Thiết kế và hiện thực giao diện web hỗ trợ người dùng thực hiện các truy vấn video bằng nhiều phương thức (truy vấn văn bản, đối tượng, OCR), và hiển thị kết quả tìm kiếm có khả năng điều hướng chính xác đến khung hình mong muốn trong video.

1.4 Phương pháp thực hiện

Nghiên cứu này triển khai quy trình xây dựng hệ thống truy xuất video toàn diện, kết hợp giữa kiến thức lý thuyết và các công nghệ tiên tiến trong thị giác máy tính, xử lý ngôn ngữ tự nhiên và hệ thống lưu trữ dữ liệu lớn. Các bước chính bao gồm:

- **Phân đoạn và trích chọn khung hình chính (Keyframe Detection):** Sử dụng mô hình *TransNet V2* để chia nhỏ video thành các đoạn (shot) và lựa chọn khung hình đại diện. Điều này giúp giảm số lượng dữ liệu cần xử lý, đồng thời đảm bảo vẫn giữ được các đặc trưng quan trọng của nội dung video.
- **Nhúng video và truy vấn thành vector:** Áp dụng các mô hình vision-language hiện đại như *CLIP*, *BLIP*, hoặc *BEiT3* để mã hóa khung hình video và truy vấn văn bản vào cùng một không gian vector, hỗ trợ tìm kiếm ngữ nghĩa hiệu quả.
- **Truy xuất dựa trên phát hiện đối tượng (Object Detection-Based Search):** Sử dụng mô hình như *YOLOv8* để phát hiện các đối tượng xuất hiện trong khung hình video. Truy vấn có thể dựa theo nhãn đối tượng, vị trí hoặc số lượng trong một frame.
- **Truy xuất dựa trên văn bản trong ảnh (OCR-Based Search):** Sử dụng các mô hình nhận diện ký tự quang học (OCR) như *PARSeq* để trích xuất văn bản xuất hiện trong video. Người dùng có thể truy vấn theo từ khóa có trong bảng hiệu, biển số, phụ đề,...

- **Lưu trữ và tìm kiếm hiệu quả:** Tận dụng thư viện *FAISS* (*Facebook AI Similarity Search*) để lưu trữ và tìm kiếm gần đúng trong không gian vector có kích thước lớn, đảm bảo tốc độ phản hồi nhanh và mở rộng tốt khi dữ liệu tăng lên.
- **Thiết kế giao diện web thân thiện người dùng:** Phát triển hệ thống giao diện web trực quan, hỗ trợ người dùng thực hiện truy vấn video thông qua các hình thức khác nhau như văn bản, hình ảnh hoặc lựa chọn đối tượng.
- **Hỗ trợ tìm kiếm theo thời gian (Nearest Neighbor Search):** Cho phép điều hướng từ keyframe đến các đoạn video lân cận về mặt thời gian, hỗ trợ truy xuất liên mạch trong ngữ cảnh toàn cục của video.

Chương 2. CƠ SỞ LÝ THUYẾT

2.1 Mô hình CLIP và các mô hình tương tự

Mô hình CLIP (*Contrastive Language–Image Pre-training*) là một mạng nơ-ron tiên tiến được thiết kế để học các khái niệm trực quan từ sự giám sát tự nhiên của ngôn ngữ. CLIP nổi bật nhờ khả năng thực hiện các nhiệm vụ phân loại hình ảnh bằng cách sử dụng các nhãn định nghĩa bằng ngôn ngữ tự nhiên, tương tự như cách các mô hình NLP như GPT-2 và GPT-3 thực hiện nhiệm vụ *zero-shot*. CLIP mở rộng khả năng của các mô hình học sâu truyền thống trong lĩnh vực thị giác máy tính, nhằm giải quyết một số vấn đề lớn:

- **Chi phí dữ liệu:** Các mô hình thị giác truyền thống yêu cầu các bộ dữ liệu được gán nhãn thủ công với chi phí lớn. CLIP, thay vào đó, học từ các cặp văn bản–hình ảnh có sẵn rộng rãi trên Internet.
- **Khả năng tổng quát:** Các mô hình truyền thống thường chỉ tốt ở một nhiệm vụ cụ thể. CLIP có khả năng tổng quát hóa và thực hiện nhiều nhiệm vụ khác nhau mà không cần huấn luyện lại trên dữ liệu chuyên biệt.
- **hiệu suất ứng dụng thực tế:** Các mô hình học sâu thường có hiệu suất tốt trên các bài kiểm tra chuẩn hóa nhưng lại không đáp ứng được kỳ vọng khi triển khai trong thực tế. CLIP, nhờ vào khả năng học dựa trên ngôn ngữ tự nhiên, cải thiện khoảng cách này bằng cách học cách biểu diễn khái niệm trực quan một cách toàn diện hơn [2].


2.1.1 Nguyên lý hoạt động của CLIP

CLIP được huấn luyện trên một nhiệm vụ tương phản đơn giản nhưng hiệu quả: dự đoán văn bản phù hợp nhất với một hình ảnh từ một tập hợp lớn các mô tả ngẫu nhiên [2]. Bằng cách này, mô hình học cách nhận diện một loạt các khái niệm trực quan và liên kết chúng với mô tả bằng ngôn ngữ tự nhiên. Quá trình này cho phép CLIP áp dụng vào nhiều nhiệm vụ phân loại hình ảnh mà không cần huấn luyện thêm.

Mô hình CLIP bao gồm hai thành phần chính:

- **Bộ mã hóa hình ảnh (Image Encoder):** Sử dụng các kiến trúc tiên tiến như Vision Transformer (ViT) hoặc ResNet để chuyển đổi hình ảnh thành vector đặc trưng.
- **Bộ mã hóa ngôn ngữ (Text Encoder):** Sử dụng Transformer để chuyển đổi văn bản thành vector đặc trưng.

Cả hai thành phần được huấn luyện với mục tiêu tương phản (*contrastive objective*), trong đó vector của hình ảnh và văn bản liên kết sẽ có khoảng cách nhỏ trong không gian đặc trưng, trong khi các cặp không liên kết sẽ có khoảng cách lớn.




Hình 2.1 Nguyên lý hoạt động của huấn luyện CLIP

2.1.2 Lợi thế và ứng dụng của CLIP

Nhờ khả năng học đa nhiệm và không phụ thuộc vào dữ liệu gán nhãn thủ công, CLIP có nhiều lợi thế:

- **Học không cần gán nhãn:** CLIP tận dụng dữ liệu ngôn ngữ tự nhiên và hình ảnh có sẵn, giảm chi phí thu thập dữ liệu.

- **Tổng quát hóa mạnh mẽ:** CLIP hoạt động tốt trên nhiều tập dữ liệu khác nhau, từ phân loại đối tượng chi tiết đến nhận dạng hành động trong video.
- **Hiệu suất zero-shot:** CLIP có thể thực hiện các nhiệm vụ chưa từng được huấn luyện trực tiếp bằng cách áp dụng các mô tả bằng ngôn ngữ tự nhiên.



Hình 2.2 minh họa mối tương quan giữa văn bản và hình ảnh trong mô hình CLIP

2.1.3 Hạn chế của CLIP

Mặc dù CLIP có nhiều ưu điểm, mô hình vẫn tồn tại một số hạn chế:

- **hiệu quả không đồng đều:** CLIP không tốt trong các nhiệm vụ trừu tượng như đếm số lượng đối tượng hoặc nhận dạng phân loại chi tiết.
- **Phụ thuộc vào ngữ cảnh ngôn ngữ:** Kết quả của CLIP có thể nhạy cảm với cách diễn đạt văn bản, đòi hỏi phải tinh chỉnh “prompt engineering”.
- **Khả năng khái quát hóa:** CLIP có thể gặp khó khăn khi làm việc với các hình ảnh không được bao phủ trong tập dữ liệu tiền huấn luyện, chẳng hạn như chữ viết tay trong OCR.


2.1.4 Vai trò trong nghiên cứu hiện tại

Các nguyên lý và lợi ích của CLIP được áp dụng vào việc phát triển các hệ thống truy xuất video. Trong nghiên cứu này, các khái niệm tương tự CLIP được sử dụng


để nhúng hình ảnh và video thành vector, sau đó kết hợp với các công cụ tìm kiếm vector như FAISS để thực hiện truy xuất nhanh chóng và chính xác. Điều này không chỉ giúp cải thiện hiệu năng mà còn nâng cao khả năng hỗ trợ người dùng trong các kịch bản tìm kiếm thực tế.

2.1.5 Mô hình BEIT3

1. **Hội tụ đa phương thức (Multimodal Convergence):** Mô hình BEIT-3 tập trung vào việc xây dựng một mô hình nền tảng có thể xử lý nhiều phương thức (hình ảnh, văn bản, và cặp hình ảnh-văn bản) thông qua việc sử dụng Multiway Transformers, giúp mô hình này có thể linh hoạt chuyển giao giữa các nhiệm vụ mà không cần phải thay đổi cấu trúc mô hình.
 - Phân loại hình ảnh, nhận diện đối tượng, phân đoạn ngữ nghĩa (một bộ mã hóa thị giác).
 - Truy xuất hình ảnh-văn bản hiệu quả (bộ mã hóa đôi).
 - Hiểu và sinh dữ liệu đa phương thức (hình ảnh + văn bản) với bộ mã hóa kết hợp.
 - Sinh văn bản từ hình ảnh (học theo cơ chế sequence-to-sequence).
2. **Mô hình hóa dữ liệu bị che khuất (Masked Data Modeling):** Thay vì thực hiện nhiều nhiệm vụ huấn luyện trước phức tạp, BEIT-3 chỉ sử dụng một nhiệm vụ duy nhất là "mask-then-predict", điều này giúp giảm độ phức tạp và tăng hiệu quả huấn luyện. Hình ảnh được đối xử như một ngôn ngữ lạ, từ đó việc học sự kết nối giữa văn bản và hình ảnh trở nên hiệu quả hơn.
3. **Mở rộng quy mô:** BEIT-3 áp dụng nguyên lý tăng quy mô mô hình và dữ liệu, giúp mô hình có khả năng tổng quát tốt hơn, từ đó có thể chuyển giao đến nhiều nhiệm vụ thực tế mà không bị hạn chế bởi kích thước mô hình.
4. **Hiệu suất xuất sắc:** BEIT-3 đã đạt được kết quả xuất sắc trên nhiều nhiệm vụ thị giác và thị giác-ngôn ngữ, chứng tỏ sức mạnh của mô hình khi được huấn luyện đúng cách và với tài nguyên đầy đủ, kể cả khi chỉ sử dụng tài nguyên công khai, hiện tại là một trong những mô hình tiên tiến nhất (state-of-the-art) 2.4 [3].



Hình 2.3 BEIT-3 có thể được chuyển giao cho nhiều nhiệm vụ hạ nguồn về thị giác và thị giác-ngôn ngữ. Với Multiway Transformer chung, chúng ta có thể tái sử dụng mô hình dưới dạng (a)(b) các bộ mã hóa thị giác hoặc ngôn ngữ; (c) các bộ mã hóa kết hợp mã hóa đồng thời các cặp hình ảnh-văn bản để tạo ra sự tương tác sâu sắc; (d) các bộ mã hóa đôi mã hóa riêng biệt các phương thức cho việc truy xuất hiệu quả; (e) học theo dạng sequence-to-sequence cho việc sinh văn bản từ hình ảnh.



Hình 2.4 Hiệu suất của BEIT3

2.2 Phát hiện đối tượng bằng YOLOv8 và lưu trữ thông tin phục vụ truy hồi

2.2.1 Tổng quan về phát hiện đối tượng (Object Detection)

Phát hiện đối tượng (*Object Detection*) là một trong những nhiệm vụ quan trọng của thị giác máy tính (*Computer Vision*), với mục tiêu xác định sự hiện diện và vị trí của các đối tượng trong ảnh hoặc video.

Không giống như bài toán phân loại (*classification*) – chỉ cho biết hình ảnh chứa đối tượng gì – phát hiện đối tượng đồng thời chỉ rõ tọa độ không gian của từng đối tượng trong ảnh thông qua các khung giới hạn (*bounding boxes*).

Một hệ thống phát hiện đối tượng hiệu quả cần giải quyết đồng thời hai vấn đề:

- **Xác định vị trí (Localization):** Ước lượng chính xác tọa độ khung giới hạn cho từng đối tượng.

- **Phân loại (Classification):** Gán nhãn lớp phù hợp cho mỗi đối tượng được phát hiện.

Các ứng dụng tiêu biểu bao gồm: giám sát an ninh, xe tự hành, đếm số lượng người/phương tiện, phân tích hành vi, và đặc biệt là truy hồi hình ảnh/video theo nội dung.

2.2.2 YOLOv8: Phương pháp phát hiện nhanh và chính xác

1. Kiến trúc tổng quát của YOLOv8

YOLO (You Only Look Once) là một họ các mô hình phát hiện đối tượng nổi bật thuộc nhóm *one-stage detectors*, trong đó việc phát hiện và phân loại đối tượng được thực hiện trong một bước duy nhất. Phiên bản mới nhất là **YOLOv8**, do Ultralytics phát triển, được cải tiến mạnh mẽ về cả tốc độ xử lý và độ chính xác.

Mô hình YOLOv8 bao gồm ba thành phần chính:

- **Backbone:** Mạng tích chập (CNN) dùng để trích xuất đặc trưng từ ảnh đầu vào.
- **Neck:** Kết hợp đặc trưng từ nhiều cấp độ khác nhau để tăng khả năng nhận dạng đối tượng với kích thước thay đổi (sử dụng FPN và PAN).
- **Head:** Dự đoán các thông tin liên quan đến đối tượng: vị trí, nhãn lớp và độ tin cậy.

Mỗi đối tượng được phát hiện sẽ được biểu diễn dưới dạng vector đặc trưng gồm sáu giá trị:

$$[x, y, w, h, c, \text{class}]$$

Trong đó:

- (x, y) là tọa độ trung tâm của khung giới hạn.
- (w, h) là chiều rộng và chiều cao của khung giới hạn.
- c là độ tin cậy (confidence score) của mô hình.

- *class* là nhãn lớp dự đoán.

2. Ưu điểm của YOLOv8

YOLOv8 mang lại nhiều lợi thế đáng kể so với các phương pháp phát hiện đối tượng khác:

- Hiệu năng cao: xử lý thời gian thực với độ chính xác tốt.
- Cấu trúc gọn nhẹ, phù hợp với cả các thiết bị giới hạn tài nguyên.
- Dễ dàng tích hợp trong pipeline thị giác nhờ đầu ra chuẩn hoá.

2.2.3 Lưu trữ thông tin phát hiện phục vụ truy hồi nội dung

1. Thông tin cần lưu trữ

Sau khi các đối tượng được phát hiện, thông tin cần thiết phải được lưu lại nhằm phục vụ hệ thống truy hồi ảnh/video theo nội dung. Đối với mỗi ảnh hoặc khung hình (frame), cần lưu trữ:

- Định danh ảnh hoặc frame (tên tệp hoặc chỉ số thời gian).
- Danh sách các đối tượng được phát hiện, mỗi đối tượng gồm:
 - Nhãn lớp (*class_name* hoặc *class_id*).
 - Tọa độ khung giới hạn: (x_1, y_1, x_2, y_2) .
 - (Tùy chọn) Độ tin cậy (confidence score).

2. Biểu diễn dữ liệu

Có thể lưu dữ liệu dưới định dạng như JSON, CSV hoặc trong cơ sở dữ liệu. Ví dụ cấu trúc biểu diễn bằng JSON:

```
{
  "image_id": "frame_001.jpg",
  "objects": [
    {"class_name": "person", "bbox": [45, 78, 200, 340]},
    {"class_name": "car", "bbox": [300, 120, 450, 300]}
  ]
}
```

2.2.4 Ứng dụng trong hệ thống truy hồi nội dung

- **Truy hồi theo lớp đối tượng:** Ví dụ: tìm tất cả các video chứa người hoặc xe hơi.
- **Truy hồi theo vị trí:** Tìm ảnh có người đứng bên trái chiếc xe.

2.3 Nhận dạng ký tự quang học (OCR) và ứng dụng trong truy xuất thông tin

2.3.1 Tổng quan về OCR trong ảnh và video

Optical Character Recognition (OCR) là quá trình tự động phát hiện và nhận dạng ký tự văn bản xuất hiện trong hình ảnh hoặc video. OCR đóng vai trò quan trọng trong nhiều ứng dụng thực tế như số hóa tài liệu, hệ thống lái xe tự động, dịch biển báo, và đặc biệt là trong các hệ thống truy xuất thông tin theo nội dung (*Content-based Retrieval*).

Khác với nhận dạng văn bản trong tài liệu được scan (có độ phân giải cao, phong chữ chuẩn), nhận dạng văn bản trong cảnh thực (*Scene Text Recognition – STR*) đòi hỏi phải xử lý các yếu tố phức tạp hơn như:

- Văn bản bị cong, xoay, hoặc bố trí ngẫu nhiên.
- Phong chữ đa dạng, chất lượng ảnh thấp, mờ, nhiễu.
- Nhiều ngôn ngữ, bao gồm cả tiếng Việt với dấu.

Để giải quyết bài toán này, hệ thống OCR hiện đại thường chia thành hai giai đoạn chính:

1. **Phát hiện vùng chứa văn bản (text detection):** Xác định vị trí vùng có chứa văn bản.
2. **Nhận dạng văn bản (text recognition):** Trích xuất nội dung văn bản từ vùng đã phát hiện.

2.3.2 Phát hiện vùng văn bản với DeepSolo

DeepSolo [4] là phương pháp phát hiện và nhận dạng văn bản end-to-end do Meta AI phát triển, thuộc nhóm phương pháp DETR-like sử dụng Transformer. Trong luận văn này, DeepSolo được sử dụng như một **detector** chuyên biệt cho văn bản tiếng Anh để *phát hiện các vùng có thể chứa văn bản*, trả về tọa độ của các khung giới hạn (bounding boxes) và điểm trung tâm (Bezier center lines).

Khác với các phương pháp truyền thống như EAST, CTPN hoặc các phương pháp cần hậu xử lý phức tạp, DeepSolo có các đặc điểm nổi bật:

- Sử dụng các **point queries** kết hợp với đường cong Bezier để phát hiện văn bản có hình dạng bất kỳ.
- Mô hình hóa phát hiện văn bản như một bài toán *object detection* không cần NMS.
- Cho phép tương thích cả với dạng annotation theo đường cong (line) và dạng bbox.

Do không hỗ trợ nhận dạng tiếng Việt, DeepSolo chỉ được sử dụng để phát hiện vùng văn bản, đảm bảo độ chính xác cao và không ảnh hưởng đến bước nhận dạng nội dung sau đó.

2.3.3 Nhận dạng ký tự tiếng Việt với PARSeq

Sau khi xác định được các vùng văn bản bằng DeepSolo, hệ thống sử dụng **PARSeq** [5] để thực hiện bước **nhận dạng nội dung văn bản** từ các ảnh cắt (cropped image regions). PARSeq là mô hình nhận dạng văn bản mạnh mẽ sử dụng Transformer kết hợp với kỹ thuật *Permutation Language Modeling (PLM)*, do nhóm nghiên cứu tại Đại học Philippines phát triển.

PARSeq được huấn luyện trước bằng dữ liệu tiếng Việt, nên có khả năng nhận dạng tốt văn bản tiếng Việt với dấu, viết hoa/thường, hoặc ký tự đặc biệt.

Các đặc điểm nổi bật của PARSeq:

- Hỗ trợ cả decoding tuần tự (AR) và song song (NAR).

- Khả năng refinement lặp giúp tăng độ chính xác đầu ra.
- Không cần mô hình ngôn ngữ bên ngoài, giảm chi phí tính toán.

Pipeline xử lý kết hợp DeepSolo và PARSeq như sau:

1. Dùng DeepSolo để phát hiện các bounding boxes chứa văn bản trong ảnh/video.
2. Cắt từng vùng ảnh theo bbox thu được.
3. Đưa từng ảnh cắt vào mô hình PARSeq đã huấn luyện tiếng Việt để thu được chuỗi ký tự tương ứng.

2.3.4 Truy xuất nội dung dựa trên kết quả OCR

Thông tin thu được từ pipeline OCR có thể được sử dụng để xây dựng hệ thống truy xuất ảnh/video theo nội dung dựa trên ký tự, cụ thể như sau:

- **Truy xuất theo từ khóa:** Người dùng nhập một từ khóa, hệ thống trả về các ảnh/video chứa văn bản phù hợp (dựa trên kết quả PARSeq).
- **Truy xuất theo vị trí:** Kết hợp thông tin bbox từ DeepSolo để truy vấn văn bản xuất hiện ở vùng cụ thể trong ảnh (góc trái trên, trung tâm, v.v.).
- **Chỉ mục hóa dữ liệu đa phương tiện:** Tự động trích xuất và lưu trữ tất cả các văn bản trong ảnh/video để tạo thành bộ từ khóa tìm kiếm.

2.3.5 Đánh giá hiệu suất của hệ thống OCR tích hợp DeepSolo và PARSeq

Việc xây dựng hệ thống nhận dạng văn bản tích hợp trong hệ thống truy xuất ảnh/video không chỉ đòi hỏi độ chính xác cao, mà còn yêu cầu hiệu suất xử lý tốt để đảm bảo khả năng áp dụng trong thực tế. Do đó, trong nghiên cứu này, chúng tôi lựa chọn hai mô hình **DeepSolo** và **PARSeq** không chỉ vì chất lượng đầu ra mà còn vì các đặc điểm hiệu năng nổi bật:

1. Hiệu suất của DeepSolo (phát hiện văn bản):

- DeepSolo đạt tốc độ khoảng **17 FPS** (khung hình/giây) trên GPU A100 với backbone ResNet-50, đủ để xử lý video gần thời gian thực.
- Nhờ thiết kế dựa trên kiến trúc DETR, DeepSolo không cần sử dụng Non-Maximum Suppression (NMS), giúp giảm đáng kể thời gian hậu xử lý.
- Sử dụng Bezier Center Curve thay vì bounding box truyền thống giúp mô hình hoạt động hiệu quả trên các văn bản cong hoặc bị xoay.

2. Hiệu suất của PARSeq (nhận dạng văn bản):

- PARSeq là một trong những mô hình STR nhanh và chính xác nhất hiện nay: đạt **96.0% độ chính xác từ đầu đến cuối (E2E)** khi huấn luyện với dữ liệu thực (real datasets).
- Mô hình hỗ trợ song song hóa cao nhờ cơ chế non-autoregressive decoding (NAR), giúp giảm latency khi xử lý nhiều vùng văn bản cùng lúc.
- Việc chỉ sử dụng một decoder Transformer nông (1 layer) giúp giảm số lượng tham số, FLOPS, và bộ nhớ sử dụng trong quá trình suy luận.

2.4 Index-Based Nearest Neighbor Search

Để truy xuất các ảnh lân cận của một frame A có tên `LxxVxxFrame_yyyy.jpg`, ta định nghĩa một phương pháp tìm kiếm lân cận dựa trên chỉ số (index-based neighbor search). Mục tiêu là lấy k ảnh trước và k ảnh sau frame A trong cơ sở dữ liệu D theo thứ tự sắp xếp. Giải thuật được mô tả như sau:

Algorithm 1 Index-Based Nearest Neighbor Search

Require: Frame A với chỉ số $yyyy$; cơ sở dữ liệu $D = \{LxxVxxFrame_0001.jpg, \dots, LxxVxxFrame_nnnn.jpg\}$; số lượng ảnh lân cận k

Ensure: Tập kết quả S gồm k ảnh trước và k ảnh sau A

```
1:  $S \leftarrow \emptyset$  ▷ Khởi tạo tập kết quả rỗng
2:  $index \leftarrow \text{ExtractIndex}(A)$  ▷ Trích chỉ số  $yyyy$  từ tên file
3:  $left \leftarrow \max(1, index - k)$  ▷ Giới hạn dưới không nhỏ hơn 1
4:  $right \leftarrow \min(|D|, index + k)$  ▷ Giới hạn trên không vượt quá kích thước tập dữ liệu
5: for  $i \leftarrow left$  to  $index - 1$  do
6:    $S \leftarrow S \cup \{LxxVxxFrame\_i.jpg\}$ 
7: end for
8: for  $i \leftarrow index + 1$  to  $right$  do
9:    $S \leftarrow S \cup \{LxxVxxFrame\_i.jpg\}$ 
10: end for
11: return  $S$ 
```

Ghi chú:

- Thuật toán này là một dạng đơn giản của *Nearest Neighbor Search* trong không gian chỉ số (index space), sử dụng khoảng cách $d(i, j) = |i - j|$.
- Thích hợp cho các bài toán truy xuất lân cận trong chuỗi thời gian như video hoặc tín hiệu tuần tự.

2.5 Database và faiss

2.5.1 Vector database là gì?

Vector Database (Cơ sở dữ liệu vector) là một loại cơ sở dữ liệu được thiết kế để lưu trữ và quản lý các vector (các dãy số hoặc mảng số học) với mục đích hỗ trợ các phép toán tìm kiếm sự tương đồng (similarity search) hoặc phân tích dữ liệu theo không gian vector. Những vector này thường được tạo ra từ các mô hình học máy hoặc học sâu (deep learning), đặc biệt là trong các bài toán xử lý văn bản, hình

ảnh, âm thanh, video hoặc bất kỳ loại dữ liệu nào có thể được biểu diễn dưới dạng các vector.

2.5.2 *MongoDB là gì?*

MongoDB là một hệ quản trị cơ sở dữ liệu NoSQL mã nguồn mở, dựa trên mô hình document-oriented (định hướng tài liệu). Dữ liệu trong MongoDB được lưu trữ dưới dạng document (tài liệu) sử dụng định dạng BSON (Binary JSON). Điều này cho phép lưu trữ và xử lý dữ liệu một cách linh hoạt và dễ dàng hơn so với các cơ sở dữ liệu quan hệ truyền thống (RDBMS).

Đặc điểm nổi bật của MongoDB:

- Cấu trúc dữ liệu linh hoạt
- Khả năng mở rộng cao (Scalability)
- Tính năng GridFS cho phép lưu trữ và truy xuất các tệp lớn (như ảnh, video) một cách hiệu quả trong MongoDB.
- Chỉ mục (Indexing)

2.5.3 *Faiss là gì?*

Faiss, viết tắt của Facebook AI Similarity Search, là một thư viện mã nguồn mở được xây dựng để tìm kiếm sự tương đồng và phân cụm các vector dày đặc. Faiss có thể được sử dụng để xây dựng chỉ mục và thực hiện tìm kiếm với tốc độ và hiệu quả bộ nhớ vượt trội. Ngoài ra, nó còn nâng cao hiệu suất tìm kiếm thông qua các triển khai GPU cho nhiều phương pháp lập chỉ mục khác nhau [6].

1. Chức năng cốt lõi

Faiss giúp tìm kiếm gần nhất nhanh chóng bằng cách lập chỉ mục các vector sử dụng các thuật toán tinh vi như phân cụm k-means và định lượng sản phẩm. Các phương pháp này giúp Faiss tổ chức và truy xuất các vector một cách hiệu quả, đảm bảo rằng việc tìm kiếm sự tương đồng sẽ nhanh chóng và chính xác. Dưới đây là cái nhìn sâu hơn về các thuật toán lập chỉ mục:

- Phân cụm k-means: Thuật toán này chia dữ liệu thành các cụm, giúp thu

hợp không gian tìm kiếm bằng cách tập trung vào các cụm có liên quan nhất trong quá trình truy vấn.

- Định lượng sản phẩm (PQ): PQ nén các vector thành các mã ngắn hơn, giảm sử dụng bộ nhớ một cách đáng kể và tăng tốc quá trình tìm kiếm mà không làm giảm quá nhiều độ chính xác.
- Định lượng sản phẩm tối ưu (OPQ): Phiên bản nâng cao của PQ, OPQ xoay dữ liệu để phù hợp hơn với lưới định lượng, cải thiện độ chính xác của các vector đã nén.

2. Tính linh hoạt

Faiss rất linh hoạt khi đo lường sự tương đồng giữa các vector, cung cấp nhiều chỉ số khoảng cách để lựa chọn. Các chỉ số chính bao gồm:

- Khoảng cách Euclid: Đo khoảng cách theo đường chéo giữa hai điểm, rất hữu ích khi bạn quan tâm đến sự tương đồng hình học của các vector.
- Độ tương đồng cosine: Đo góc giữa hai vector, tập trung vào hướng của chúng thay vì độ dài. Đây là chỉ số đặc biệt hữu ích trong phân tích văn bản, nơi hướng đi quan trọng hơn độ dài.

Các lựa chọn này giúp người phát triển chọn chỉ số phù hợp nhất với dữ liệu và nhu cầu ứng dụng của mình.

Faiss có thể chạy trên cả CPU và GPU, sử dụng phần cứng hiện đại để tăng tốc quá trình tìm kiếm. Faiss được thiết kế cho nhiều nền tảng tính toán, từ máy tính cá nhân đến các cụm tính toán hiệu suất cao. Nó có thể chuyển đổi mượt mà giữa các chỉ mục CPU và GPU, và giao diện Python của nó hoạt động tốt với các chỉ mục C++, giúp việc chuyển từ thử nghiệm sang triển khai trở nên dễ dàng. Việc hỗ trợ đa nền tảng này đảm bảo rằng Faiss có thể được sử dụng hiệu quả trong nhiều môi trường tính toán khác nhau, tối ưu hóa hiệu suất và việc sử dụng tài nguyên.

2.5.4 Kiến trúc của TransNet V2

TransNet V2 sử dụng kiến trúc mạng nơ-ron tích chập 3D (3D CNN) để khai thác thông tin không gian và thời gian từ chuỗi khung hình. Mô hình bao gồm hai nhánh:

- **Nhánh đơn khung hình:** Phân tích từng khung hình riêng lẻ để phát hiện chuyển đổi cảnh.
- **Nhánh toàn khung hình:** Phân tích toàn bộ chuỗi khung hình để xác định các chuyển đổi cảnh phức tạp hơn.

Sự kết hợp của hai nhánh này giúp TransNet V2 đạt được độ chính xác cao trong việc phát hiện cả chuyển đổi cắt và chuyển đổi mờ dần.

2.5.5 Dữ liệu huấn luyện

TransNet V2 được huấn luyện trên tập dữ liệu kết hợp giữa các chuyển đổi cảnh thực tế (15%) và chuyển đổi cảnh tổng hợp (85%) được tạo từ hai tập dữ liệu IACC.3 và ClipShots [7]. Việc sử dụng dữ liệu tổng hợp giúp mô hình học được nhiều loại chuyển đổi cảnh khác nhau, cải thiện khả năng tổng quát hóa.

2.5.6 Hiệu suất và ứng dụng

TransNet V2 đạt hiệu suất cao trên các bộ dữ liệu chuẩn như ClipShots, BBC Planet Earth và RAI, với điểm F1 lần lượt là 77.9, 96.2 và 93.9 [7]. Mô hình có thể được sử dụng trong các ứng dụng như:

- Tóm tắt video tự động
- Tìm kiếm và truy xuất nội dung video
- Phân tích và gắn thẻ cảnh trong video
- Tiền xử lý dữ liệu cho các mô hình học sâu khác

Chương 3. NỘI DUNG THỰC HIỆN

3.1 Yêu cầu đối với hệ thống

Hệ thống truy xuất thông tin từ video cần đáp ứng các yêu cầu kỹ thuật sau:

- **Hiệu suất truy vấn:** Thời gian trả về khung hình phù hợp nhất phải nhỏ hơn **1 giây** trên tập dữ liệu $\geq 500\,000$ ảnh.
- **Khả năng mở rộng:** Có khả năng xử lý bộ dữ liệu quy mô hàng triệu khung hình và hỗ trợ tích hợp nhiều nguồn video đầu vào (YouTube, ổ cứng cục bộ, cloud, v.v.).
- **Truy vấn ngôn ngữ tự nhiên:** Cho phép người dùng nhập truy vấn bằng tiếng Việt; hệ thống sẽ tự động dịch sang tiếng Anh để tương thích với các mô hình embedding tiền huấn luyện như BEiT3 hoặc CLIP.
- **Liên kết theo thời gian:** Mỗi khung hình truy xuất được gắn kèm URL và mốc thời gian tương ứng trong video gốc để xác minh và đối chiếu ngữ cảnh.
- **Giao diện trực quan:** Cung cấp trình xem ảnh độ phân giải cao, hỗ trợ phóng to/thu nhỏ, điều hướng giữa các khung hình và xem video gốc thông qua tích hợp nhúng YouTube hoặc các dịch vụ tương đương.

3.2 Các chế độ truy xuất trong hệ thống VBS-Web Server

VBS-Web Server là dịch vụ backend được phát triển bằng ngôn ngữ Python, đóng vai trò là động cơ tìm kiếm chính cho ứng dụng VBS-Web. Hệ thống hỗ trợ truy xuất thông tin theo nhiều phương thức khác nhau, đáp ứng nhu cầu tìm kiếm phong phú của người dùng. Cụ thể, có bốn chế độ truy xuất chính như sau:

- **Tìm kiếm ngữ nghĩa từ văn bản đến hình ảnh** (*Text-to-Image Semantic Search*): Người dùng nhập câu truy vấn, hệ thống sử dụng mô hình BEiT3 để mã hoá thành vector embedding, sau đó tìm kiếm khung hình gần nhất trong không gian nhúng sử dụng FAISS.

- **Tìm kiếm dựa trên phát hiện đối tượng (*Object Detection-Based Search*):** Hệ thống lọc các khung hình có chứa một hoặc nhiều đối tượng được chỉ định, hỗ trợ logic tổ hợp (AND/OR) để nâng cao độ chính xác.
- **Tìm kiếm văn bản trong ảnh (OCR) (*OCR-Based Search*):** Truy vấn dựa trên chuỗi ký tự được trích xuất từ ảnh bằng mô hình OCR (ví dụ: PARSeq). Hệ thống hỗ trợ so khớp mờ (*fuzzy matching*) để tìm chính xác hơn trong trường hợp nhận dạng bị sai lệch.
- **Tìm kiếm khung hình lân cận (*Nearest neighbor Search*):** Trả về một cụm các khung hình trước/sau một frame tham chiếu để cung cấp bối cảnh hình ảnh liên mạch trong đoạn video.

3.3 Các chế độ truy xuất trong hệ thống VBS-Web Server


VBS-Web Server là dịch vụ backend được phát triển bằng ngôn ngữ Python, đóng vai trò là động cơ tìm kiếm chính cho ứng dụng VBS-Web. Hệ thống hỗ trợ truy xuất thông tin theo nhiều phương thức khác nhau, đáp ứng nhu cầu tìm kiếm phong phú của người dùng. Cụ thể, có bốn chế độ truy xuất chính như sau:

- **Tìm kiếm ngữ nghĩa từ văn bản đến hình ảnh (*Text-to-Image Semantic Search*):** Người dùng nhập câu truy vấn, hệ thống sử dụng mô hình BEiT3 để mã hoá thành vector embedding, sau đó tìm kiếm khung hình gần nhất trong không gian nhúng sử dụng FAISS.
- **Tìm kiếm dựa trên phát hiện đối tượng (*Object Detection-Based Search*):** Hệ thống lọc các khung hình có chứa một hoặc nhiều đối tượng được chỉ định, hỗ trợ logic tổ hợp (AND/OR) để nâng cao độ chính xác.
- **Tìm kiếm văn bản trong ảnh (OCR) (*OCR-Based Search*):** Truy vấn dựa trên chuỗi ký tự được trích xuất từ ảnh bằng mô hình OCR (ví dụ: PARSeq). Hệ thống hỗ trợ so khớp mờ (*fuzzy matching*) để tìm chính xác hơn trong trường hợp nhận dạng bị sai lệch.
- **Tìm kiếm khung hình lân cận (*nearest neighbor Search*):** Trả về một cụm các khung hình trước/sau một frame tham chiếu để cung cấp bối cảnh hình ảnh liên mạch trong đoạn video.

3.4 Giai đoạn xử lý và lưu trữ thông tin

Hệ thống truy xuất ảnh từ video được xây dựng dựa trên một chuỗi xử lý đa giai đoạn, trong đó giai đoạn đầu tiên tập trung vào việc trích xuất, phân tích và lưu trữ các đặc trưng hình ảnh từ video đầu vào. Các bước chính bao gồm:


1. **Phân đoạn cảnh (Scene segmentation):** Sử dụng mô hình **TransNet V2** để phát hiện các điểm chuyển cảnh trong video.
2. **Trích xuất khung hình chính (Keyframe extraction):** Lấy một khung hình đại diện từ mỗi cảnh, sau đó loại bỏ các khung hình trùng lặp nội dung bằng phương pháp **cosine similarity deduplication**.
3. **Sinh vector đặc trưng (Embedding):** Ánh xạ khung hình thành vector nhúng sử dụng mô hình **BEIT3**.
4. **Phát hiện đối tượng và văn bản:**
 - Dùng **YOLOv8** để nhận diện đối tượng, tạo ra nhãn lớp và tọa độ bounding box.
 - Kết hợp **DeepSolo** và **PARSeq** để phát hiện và nhận dạng văn bản (OCR).
5. **Lưu trữ đặc trưng:**
 - Lưu vector đặc trưng vào hệ thống **FAISS** để hỗ trợ tìm kiếm ngữ nghĩa.
 - Lưu thông tin đối tượng, văn bản, timestamp và metadata vào **MongoDB**.



Hình 3.5 Pipeline xử lý và lưu trữ thông tin từ video

3.5 Giai đoạn truy vấn và truy xuất thông tin

Khi người dùng đưa ra một truy vấn bằng văn bản, hệ thống sử dụng các kỹ thuật học sâu để mã hóa truy vấn và tìm ra khung hình phù hợp nhất. Bên cạnh đó, hệ thống còn hỗ trợ các chế độ truy xuất linh hoạt như truy vấn theo object, văn bản hoặc khung hình liên kề 3.6.



Hình 3.6 Các cơ chế tìm kiếm trong hệ thống truy xuất VBS-Web

1. **Truy vấn ngôn ngữ tự nhiên**: Câu truy vấn tiếng Việt được dịch sang tiếng Anh rồi mã hóa thành vector nhúng bằng mô hình **BEIT3**.
2. **Tìm kiếm ngữ nghĩa (semantic search)**: Truy vấn vector được so sánh với FAISS index để tìm ra các khung hình có nội dung tương đồng về mặt ngữ nghĩa.
3. **Tìm kiếm dựa trên đối tượng (object-based)**: Lọc các khung hình chứa một hoặc nhiều đối tượng cụ thể theo yêu cầu người dùng.
4. **Tìm kiếm văn bản (OCR-based)**: So khớp chuỗi ký tự truy vấn với văn bản trong ảnh, có hỗ trợ fuzzy search để xử lý sai lệch nhận dạng.

5. **Khung hình lân cận (nearest neighbor)** : Trả về dải khung hình trước và sau khung hình chính nhằm cung cấp thêm ngữ cảnh.
6. **Liên kết video gốc**: Mỗi khung hình kết quả đều có kèm URL và timestamp để người dùng kiểm tra trực tiếp trên nền tảng video gốc (ví dụ: YouTube).


3.6 Giải thuật chi tiết và giải thích

3.6.1 Tách khung hình chính từ video


Để truy xuất hiệu quả, cần chọn các khung hình đại diện thay vì xử lý toàn bộ khung hình trong video. Việc này giúp giảm dung lượng lưu trữ và tăng tốc độ tìm kiếm.

Quy trình:

- **Bước 1:** Sử dụng **TransNet V2** để chia video thành các cảnh liên tục.
- **Bước 2:** Chọn 3 khung hình đại diện cho mỗi cảnh: khung đầu, khung giữa và khung cuối để đảm bảo không bỏ sót thông tin quan trọng.
- **Bước 3:** Lưu trữ các khung hình lên **Google Drive** để thuận tiện cho xử lý các nhiệm vụ như object detection và ocr, ngoài lưu trữ trên ổ cứng để đảm bảo chúng không bị cấm quyền truy cập khi yêu cầu truy xuất quá nhiều.



Hình 3.7 Lựa chọn khung hình chính từ mỗi cảnh



Hình 3.8 Minh họa sau khi thực hiện TransNet V2 để lọc khung hình

3.6.2 Mã hóa khung hình bằng BEIT3

Các khung hình chính (keyframes) được ánh xạ thành vector đặc trưng bằng mô hình BEIT3, một mô hình thị giác được huấn luyện trước (pre-trained) có khả năng hiểu ngữ nghĩa hình ảnh thông qua học không giám sát.

Quy trình thực hiện:

- Đầu vào là ảnh đầu ra từ giai đoạn trích xuất keyframe.
- Mỗi ảnh được đưa qua mô hình BEIT3 để trích xuất một vector embedding có chiều cố định.
- Kỹ thuật zero-shot learning được tận dụng nhằm cho phép truy xuất theo các mô tả văn bản mới chưa từng gặp trong quá trình huấn luyện.
- Các embedding sau đó được lưu trữ vào một file JSON, với mỗi phần tử gồm:
 - frame_id: Định danh duy nhất cho khung hình.
 - frame_embedding: Mảng các giá trị thực (float) đại diện cho đặc trưng nội dung hình ảnh.

```
{
  "frames": [
    {
      "frame_id": "string_identifier",
      "frame_embedding": [
        "float_value_1",
        "float_value_2",
        "..."
      ]
    }
  ]
}
```

Hình 3.9 Cấu trúc file JSON lưu trữ vector embedding

3.6.3 Lưu trữ embedding vào FAISS

Để hỗ trợ truy xuất khung hình dựa trên mô tả ngữ nghĩa một cách hiệu quả, hệ thống sử dụng thư viện **FAISS (Facebook AI Similarity Search)** để lưu trữ và tìm kiếm các vector đặc trưng. FAISS cho phép thực hiện tìm kiếm gần đúng theo độ tương đồng cosine với tốc độ cao ngay cả khi số lượng vector lên đến hàng triệu.

Quy trình thực hiện:

1. **Đọc dữ liệu** từ file JSON chứa danh sách các vector embedding và các định danh khung hình tương ứng (`frame_id`).
2. **Khởi tạo FAISS index** với cấu trúc `IndexFlatIP` (inner product), kết hợp với lựa chọn so sánh bằng **cosine similarity** để đảm bảo tìm được các khung hình gần nhất về mặt ngữ nghĩa.
3. **Thêm toàn bộ vector** embedding vào FAISS index. Các vector đầu vào đã được sinh bởi mô hình BEIT3, đảm bảo cùng chiều và chuẩn định dạng `float32`.

4. **Lưu index** dưới dạng tệp nhị phân với phần mở rộng `.bin`, giúp dễ dàng nạp lại khi khởi động hệ thống truy vấn.

Việc sử dụng FAISS kết hợp với cosine similarity giúp hệ thống truy xuất nhanh chóng những khung hình có nội dung phù hợp nhất với truy vấn người dùng trong không gian vector ngữ nghĩa.

3.6.4 *Object Detection*

Hệ thống tích hợp mô hình **YOLOv8** để phát hiện đối tượng trong từng khung hình, nhằm tăng cường khả năng lọc và tìm kiếm theo đối tượng cụ thể. YOLOv8 là phiên bản mới nhất trong họ YOLO, nổi bật nhờ tốc độ xử lý nhanh và độ chính xác cao, phù hợp với các bài toán xử lý khối lượng lớn dữ liệu hình ảnh.

Quy trình thực hiện:

- Mỗi khung hình được đưa qua mô hình **YOLOv8** để nhận diện các đối tượng có trong ảnh.
- Đối với mỗi đối tượng phát hiện được, hệ thống ghi lại thông tin gồm:
 - `bbbox`: Tọa độ bounding box dạng `[x1, y1, x2, y2]`
 - `class_id, class_name`: ID và tên lớp đối tượng
 - `confidence`: Mức độ tin cậy của dự đoán
- Ngoài ra, hệ thống còn thống kê số lượng từng loại đối tượng xuất hiện trong ảnh (`counts`).
- Kết quả được lưu vào **file JSON**, phục vụ cho việc tìm kiếm theo object hoặc trực quan hóa bounding box trong frontend.

Định dạng JSON của Object Detection:

```
[  
  {  
    "frame_id": "/L01/L01_V001/frame_0.jpg",  
    "detections": [  

```

```
[
  {
    "bbox": [210.05, 199.48, 1105.11, 525.92],
    "class_id": 4,
    "class_name": "airplane",
    "confidence": 0.95
  },
  {
    "bbox": [213.22, 202.10, 680.60, 523.68],
    "class_id": 4,
    "class_name": "airplane",
    "confidence": 0.90
  }
],
"counts": {
  "airplane": 2
}
]
```

Bối cảnh triển khai thực nghiệm:

Để đánh giá khả năng áp dụng của pipeline phát hiện đối tượng, hệ thống được thử nghiệm trên một tập dữ liệu demo từ một thư mục L01, bao gồm 31 video tương ứng với 31 ngày quan sát khác nhau.

Việc áp dụng YOLOv8 cho từng ảnh chứng minh hiệu năng thực tế của hệ thống, đồng thời tạo nền tảng để mở rộng lên toàn bộ tập dữ liệu quy mô lớn hơn trong tương lai.

3.6.5 OCR

Hệ thống sử dụng hai mô hình **DeepSolo** và **Parseq** để trích xuất văn bản từ khung hình.

Quy trình:

- Sử dụng **DeepSolo** để phát hiện vị trí các ký tự trong ảnh, hỗ trợ nhận diện ký

tự ở các vị trí và độ cong khác nhau.

- Sử dụng **Parseq** (được fine-tune trên bộ dữ liệu tiếng Việt) để nhận diện các ký tự thành văn bản.
- Lưu trữ danh sách văn bản được trích xuất từ khung hình vào **file JSON**.

Định dạng JSON của OCR:

```
{  
  "L01_V001Frame_0.jpg": [  
    "giây",  
    "06:29:59",  
    "HD"  
  ],  
  "L01_V001Frame_10128.jpg": [  
    "mục",  
    "tiêu",  
    "mìn",  
    "tháng",  
    "tối",  
    "vào",  
    "tiến",  
    "Campuchia",  
    "2025"  
  ]  
}
```

3.7 Lưu trữ các trường trong MongoDB

Sau khi xử lý từng khung hình từ video đầu vào, hệ thống sẽ lưu thông tin vào cơ sở dữ liệu MongoDB dưới dạng tài liệu (document). Mỗi tài liệu đại diện cho một frame ảnh và chứa đầy đủ metadata cần thiết phục vụ cho việc tìm kiếm và phân tích sau này.

- **image_id**: Định danh duy nhất cho ảnh, được ghép từ mã camera, ID video và số thứ tự của frame. Ví dụ: L01_V001_09606.

- `google_drive_link`: Đường dẫn tới file ảnh gốc được lưu trữ trên Google Drive (nếu có sử dụng dịch vụ lưu trữ đám mây).
- `l, v`: Thể hiện camera thứ `l` và video thứ `v` tại camera đó.
- `sequence_number`: Số thứ tự của frame trong video, bắt đầu từ 0.
- `fps`: Số khung hình trên giây (frame per second) của video.
- `frame_stamp`: Mốc thời gian (tính bằng giây) ứng với frame hiện tại, được tính bằng công thức:

$$\text{frame_stamp} = \frac{\text{sequence_number}}{\text{fps}}$$

- `watch_url`: Đường dẫn tới video gốc trên YouTube hoặc nền tảng tương tự, có thể kèm timestamp.
- `detected_objects`: Danh sách tên các đối tượng được phát hiện trong ảnh, không trùng lặp. Ví dụ: `["person", "car", "stop sign"]`.
- `object_counts`: Một đối tượng JSON đếm số lượng của từng loại object phát hiện được.
- `detections`: Danh sách chi tiết thông tin từng đối tượng phát hiện, gồm lớp (class), độ tin cậy (score) và tọa độ bounding box.
- `text`: Danh sách các từ được nhận diện trong ảnh bằng mô hình OCR, phục vụ cho việc tìm kiếm văn bản trong ảnh.

Tất cả các trường trên được lưu trữ trong MongoDB dưới dạng document theo chuẩn JSON, giúp dễ dàng mở rộng, truy vấn linh hoạt và hỗ trợ tích hợp các công cụ tìm kiếm nâng cao như Elasticsearch, fuzzy search hoặc FAISS.

3.7.1 Phân tích kiến trúc kỹ thuật của VBS-Web Server

VBS-Web Server là hệ thống backend hỗ trợ tìm kiếm hình ảnh và khung hình video theo mô tả văn bản, được xây dựng dựa trên các công nghệ hiện đại và có khả năng mở rộng cao. Với ngôn ngữ chính là Python và framework Flask, hệ thống

cung cấp API RESTful, xử lý các truy vấn từ frontend thông qua JSON, đồng thời sử dụng Redis để cache kết quả và giảm tải cho máy chủ.

Dữ liệu metadata được lưu trữ trong MongoDB với mô hình document linh hoạt, phục vụ nhanh các truy vấn liên quan đến văn bản và đối tượng. Trong khi đó, FAISS đóng vai trò là công cụ tìm kiếm vector, cho phép so khớp truy vấn văn bản (embedding từ BEiT3) với hàng trăm nghìn ảnh chỉ trong thời gian ngắn. Các mô hình học sâu như YOLOv8 (phát hiện vật thể), DeepSolo và PARSeq (OCR) cũng được tích hợp để tăng cường truy vấn đa phương thức.

Về triển khai ba dịch vụ chính: Redis, dịch vụ khởi tạo dữ liệu, và máy chủ chính. Mọi thông số cấu hình được quản lý bằng biến môi trường .env, giúp bảo mật và linh hoạt khi triển khai.


3.8 Giao diện người dùng và các phương pháp truy xuất hỗ trợ

Hệ thống VBS-Web cung cấp giao diện người dùng trực quan và linh hoạt, hỗ trợ truy vấn đa dạng dưới nhiều hình thức như văn bản, đối tượng, khung hình và văn bản trong ảnh. Mỗi chức năng đều được kết nối với các mô hình học sâu và cơ sở dữ liệu chuyên biệt, nhằm đảm bảo hiệu quả cao trong việc truy xuất thông tin từ video.


3.8.1 Thiết kế giao diện người dùng

Giao diện được chia thành ba khu vực chính:

- **Thanh truy vấn:** Cho phép nhập truy vấn văn bản tự nhiên hoặc chọn đối tượng cần tìm.
- **Vùng kết quả:** Hiển thị các khung hình phù hợp dưới dạng lưới ảnh; mỗi ảnh có kèm liên kết đến video gốc và các khung hình lân cận.
- **Khung xem chi tiết:** Hiển thị ảnh độ phân giải cao, timestamp và liên kết YouTube.



Hình 3.10 Giao diện chính của hệ thống khi truy vấn bằng văn bản




Hình 3.11 Chi tiết một khung hình sau khi chọn truy vấn

3.8.2 Tìm kiếm ngữ nghĩa dựa trên vector (Semantic Search)

Tìm kiếm ngữ nghĩa cho phép người dùng nhập mô tả tự nhiên bằng tiếng Việt để tìm ra các khung hình phù hợp nhất theo nội dung. Hệ thống sử dụng mô hình **BEiT3** để mã hóa câu truy vấn thành vector và tìm kiếm trong FAISS index bằng cosine similarity.

Quy trình:




Hình 3.12 Truy xuất khi sử dụng tiếng việt

1. Nhập truy vấn tiếng Việt → Dịch sang tiếng Anh (Google Translate).
2. Chuẩn hóa và mã hóa bằng BEiT3 → Vector embedding.
3. So sánh vector truy vấn với FAISS để lấy top- k khung hình gần nhất.
4. Trả về kết quả và timestamp liên kết video gốc.

3.8.3 Tìm kiếm văn bản trong ảnh (OCR-Based Search)

Cho phép người dùng truy vấn khung hình chứa chuỗi ký tự cụ thể như biển số xe, tên, mã định danh. Văn bản được nhận dạng bởi pipeline **DeepSolo + PARSeq** và lưu trong MongoDB 4.23.



(a) Truy vấn văn bản

(b) Kết quả trả về

Hình 3.13 Minh họa truy vấn tìm kiếm văn bản trong ảnh

Quy trình:


1. Nhập truy vấn văn bản.
2. Truy vấn MongoDB với **full-text fuzzy search**.
3. Trả về các khung hình chứa văn bản khớp gần nhất, kèm độ chính xác và vị trí.

3.8.4 Tìm kiếm dựa trên phát hiện đối tượng (*Object-Based Search*)


Tính năng này cho phép người dùng truy xuất các khung hình có chứa một hoặc nhiều đối tượng cụ thể, như person, car, motorbike,... Các đối tượng đã được phát hiện trong giai đoạn tiền xử lý bằng mô hình **YOLOv8** và lưu vào MongoDB dưới dạng nhãn và bounding box.

Quy trình thực hiện:

1. Người dùng nhập danh sách đối tượng cần tìm và chọn logic kết hợp:
 - \$all – tìm khung hình chứa **toàn bộ đối tượng** trong danh sách truy vấn (tương ứng với logic AND) (Hình 3.14).
 - \$in – tìm khung hình chứa **ít nhất một đối tượng** trong danh sách truy vấn (tương ứng với logic OR) (Hình 3.15).
2. Hệ thống truy vấn MongoDB theo điều kiện logic tương ứng và lấy danh sách các khung hình phù hợp.
3. Đối với mỗi khung hình kết quả, hệ thống tính toán điểm **IoU-based score** giữa các bounding box phát hiện và kỳ vọng từ truy vấn. Score càng cao thì độ trùng khớp về không gian giữa truy vấn và khung hình càng lớn.
4. Các khung hình được **xếp hạng theo score** và hiển thị kèm timestamp, tên đối tượng và liên kết đến thời điểm xuất hiện trong video gốc.



Hình 3.14 Tìm kiếm khi khung hình chứa **toàn bộ đối tượng** trong truy vấn (logic AND)




Hình 3.15 Tìm kiếm khi khung hình chứa **ít nhất một đối tượng** trong truy vấn (logic OR)

3.8.5 Tìm kiếm theo khung hình lân cận (nearest neighbor Search)

Chức năng này giúp người dùng mở rộng ngữ cảnh bằng cách truy xuất thêm các khung hình lân cận trước và sau khung hình chính 3.16.

Quy trình:



Hình 3.16 Tìm kiếm theo khung hình lân cận

1. Người dùng chọn một frame cụ thể (qua truy vấn chính hoặc ID).
2. Tách `frame_id` $\rightarrow$ `video_id` + `sequence_number`.
3. Truy vấn MongoDB để lấy các khung hình liên kế theo thời gian.
4. Hiển thị dạng chuỗi liên tục giúp theo dõi diễn biến.

3.8.6 Tổng hợp các phương thức truy vấn

Phương thức truy xuất	Đầu vào	Mô hình / Cơ sở dữ liệu
Truy xuất ngữ nghĩa	Văn bản (tiếng Việt / Anh)	BEiT3 + FAISS
Truy xuất theo đối tượng	Danh sách đối tượng	YOLOv8 + MongoDB
Truy xuất văn bản (OCR)	Văn bản cần tìm	DeepSolo + PARSeq + MongoDB Atlas Search
Truy xuất theo khung hình lân cận	Frame ID cụ thể	MongoDB + truy vấn theo thứ tự thời gian

Bảng 3.2 Tổng hợp các phương thức truy xuất trong hệ thống

Bảng 3.3 So sánh các phương thức truy xuất trong hệ thống

Phương thức truy xuất	Khi nào dùng	Ưu điểm	Hạn chế
Truy xuất ngữ nghĩa	Khi người dùng đưa ra câu truy vấn tổng quát, không chứa từ khóa cụ thể.	Tìm kiếm dựa trên ngữ nghĩa, không cần tag hoặc annotation thủ công.	Dễ bị mơ hồ khi truy vấn dài hoặc chứa nhiều thành phần không rõ ràng.
Truy xuất theo đối tượng	Khi truy vấn đề cập rõ đến đối tượng cụ thể như người, xe, động vật...	Cho phép truy vấn trực tiếp bằng logic hình ảnh, hỗ trợ điều kiện vị trí và số lượng.	Hạn chế khi đối tượng cần truy vấn không nằm trong danh sách nhãn được huấn luyện.
Truy xuất văn bản (OCR)	Khi hình ảnh có chứa văn bản rõ ràng như biển hiệu, ký hiệu, bảng tên.	Truy xuất văn bản chính xác, hỗ trợ tìm gần đúng (fuzzy) khi có sai lệch.	Phụ thuộc vào chất lượng nhận dạng ký tự, dễ sai khi ảnh bị mờ, nghiêng, hoặc có nhiễu.
Truy xuất theo khung hình lân cận	Khi truy vấn mô tả một chuỗi hành động liên tục theo thời gian.	Cho phép theo dõi sự kiện diễn tiến, hỗ trợ phục hồi ngữ cảnh.	Cần kiểm tra thêm thủ công các frame trước/sau để xác nhận đầy đủ nội dung.

Chương 4. KẾT QUẢ THỰC HIỆN

4.1 Thực nghiệm và Cách Đánh Giá

Phần thực nghiệm được triển khai trong khuôn khổ cuộc thi **AI Challenge Thành phố Hồ Chí Minh**, nội dung thi thuộc chủ đề *Video Retrieval* với mục tiêu truy xuất chính xác đoạn video tương ứng với truy vấn ngôn ngữ tự nhiên. Dữ liệu truy vấn là bản tin thời sự 60 phút của HTV, trong đó mỗi truy vấn tương ứng với phân đoạn có thời lượng khoảng 30 phút, thu thập trong vòng 2 năm. Cuộc thi gồm 3 vòng, lần lượt tăng độ khó và số lượng truy vấn như sau:

- **Vòng 1:** Gồm 25 truy vấn.
- **Vòng 2:** Gồm 30 truy vấn.
- **Vòng 3:** Gồm 35 truy vấn.

Có hai loại truy vấn được sử dụng trong đề bài:

1. **Truy vấn dạng mô tả (Textual KIS):** Mỗi truy vấn cung cấp một đoạn mô tả bằng ngôn ngữ tự nhiên, có thể bao gồm nhiều câu hoặc nhiều ý, yêu cầu xác định chính xác đoạn video tương ứng với sự kiện được mô tả.
2. **Truy vấn dạng Hỏi & Đáp (Q&A):** Mỗi truy vấn bao gồm một đoạn mô tả và một câu hỏi liên quan đến nội dung mô tả. Kết quả cần trả về bao gồm vị trí đoạn video và một chuỗi câu trả lời gồm các ký tự từ 0 đến 9.

Mỗi truy vấn cho phép nộp tối đa 100 bộ câu trả lời, mỗi bộ gồm:

- Tên video (`video_name`),
- Vị trí khung hình (`frame_index`),
- Câu trả lời (chỉ áp dụng cho loại Q&A).

Một câu trả lời được xem là **đúng** nếu đồng thời thỏa mãn ba điều kiện sau:

- Tên video khớp với video trong tập đáp án (GT_v).
- Vị trí khung hình thuộc đoạn $[u, v]$ xác định trong đáp án.
- Câu trả lời (nếu có) khớp với đáp án (GT_a).

Cách Tính Điểm Theo Thứ Hạng (Top-k)

Mỗi truy vấn được tính điểm theo vị trí của câu trả lời đúng đầu tiên trong tập nộ. Cụ thể:

- Nếu đáp án đúng nằm trong top 1, nhận 1 điểm.
- Nếu nằm trong top 5, nhận thêm 1 điểm.
- Nếu nằm trong top 20, nhận thêm 1 điểm.
- Nếu nằm trong top 50, nhận thêm 1 điểm.
- Nếu nằm trong top 100, nhận thêm 1 điểm.

Điểm truy vấn cuối cùng được tính bằng công thức:

$$\text{Điểm truy vấn} = \frac{S_{@1} + S_{@5} + S_{@20} + S_{@50} + S_{@100}}{5}$$

Ví dụ: Nếu đáp án đúng nằm ở vị trí thứ 24 trong tập nộ, hệ thống sẽ nhận điểm ở các mức top@50 và top@100, tổng 2 điểm, chia cho 5, kết quả là 0.4 điểm cho truy vấn đó.


Cách Tính Điểm Chung Cuộc

Mỗi vòng thi bao gồm một gói truy vấn. Tổng điểm của một vòng bằng tổng điểm của tất cả các truy vấn trong vòng đó. Sau ba vòng, tổng điểm toàn bộ được sử dụng để xếp hạng các đội thi.

Ý Nghĩa Thực Tiến

Cách đánh giá này không chỉ phản ánh độ chính xác mà còn đo lường khả năng xếp hạng kết quả hiệu quả của hệ thống truy xuất. Cơ chế này khuyến khích việc tối ưu

hóa thứ tự câu trả lời, thay vì chỉ quan tâm đến việc có câu trả lời đúng hay không. Điều này giúp định hướng các giải pháp tiếp cận bài toán theo hướng thực tế và có tính ứng dụng cao hơn.



Hình 4.17 Điểm truy vấn trung bình trong mỗi pack

Bảng 4.4 Kết quả vòng sơ tuyển cuộc thi AI Challenge TP. Hồ Chí Minh

Mục	Giá trị
Điểm Pack 1	13.0
Điểm Pack 2	20.8
Điểm Pack 3	27.8
Tổng điểm chính thức (đúng GT)	61.6
Tổng điểm tham khảo (đúng video, sai frame)	64.8

Câu truy vấn bị loại	Lý do
query-p1-3-qa	Câu truy vấn thiếu thông tin khi bắt đầu giờ thi
query-p2-27-kis	
query-p2-14-kis	Mô tả truy vấn không đủ chi tiết, dẫn đến có rất nhiều đáp án thỏa mãn
query-p3-1-kis	Mô tả truy vấn không đủ chi tiết, dẫn đến có rất nhiều đáp án thỏa mãn
query-p3-34-qa	Câu truy vấn bị trùng với đợt 2
	Câu truy vấn mô tả không chính xác

4.2 Một số mẫu câu ví dụ trong cuộc thi

4.2.1 Truy vấn với mô tả đơn giản, cụ thể

Câu truy cuộc thi cung cấp: *“Bản tin về một địa điểm. Ở địa điểm này có nhiều người chụp hình bên cạnh một bảng nhiệt độ ở ngoài trời. Bên trên là độ F, bên dưới là độ C.”*

Câu truy vấn dùng để truy vấn: có người chụp hình bên cạnh một bảng nhiệt độ ngoài trời.

- **Phương pháp truy xuất: Semantic Search (BEiT3 + FAISS)**
- **Mục tiêu:** Đánh giá khả năng của hệ thống trong việc nhận diện một khung hình cụ thể với mô tả ngắn gọn nhưng có tính nhận diện hình ảnh cao. Truy vấn không chứa từ khóa đặc biệt, nhưng mô tả cảnh vật để phân biệt bằng các chi tiết đặc trưng như bảng nhiệt độ, giá trị số và hành động chụp ảnh 4.18.
- **Phân tích:**
 - Hệ thống truy xuất chính xác chuỗi khung hình liên tiếp từ video L20_V008 hiển thị bảng điện tử ngoài trời với hai đơn vị đo nhiệt độ (Fahrenheit và Celsius), cùng nhiều người đứng tạo dáng và chụp ảnh.
 - Cảnh vật có tính nhận diện cao nên hệ thống dễ dàng đưa các kết quả phù hợp lên top đầu, dù mô tả ngắn và không có từ khóa tên riêng.
 - Các kết quả cũng cho thấy khả năng tổng hợp ngữ nghĩa từ hành động (“chụp hình”), cảnh vật (“bảng nhiệt độ”) và môi trường (“ngoài trời”).


4.2.2 Truy xuất với nhiều thông tin nhiễu do từ khóa chồng chéo

Để minh họa cho khả năng truy xuất theo ngữ nghĩa phức tạp.

Câu truy vấn đề bài cung cấp: *“Một người đàn ông đang trả lời phỏng vấn trong một lễ hội. Phía sau người đàn ông này là một vật trang trí có hình dáng con chim màu tím.”*

Câu truy vấn sử dụng trong hệ thống: một người đàn ông đang phỏng vấn trong lễ hội phía sau người đàn ông này là một vật trang trí có hình dáng con chim màu tím.

Truy vấn này bao gồm nhiều thành phần kết hợp:



Hình 4.18 Kết quả truy xuất cho truy vấn mô tả cảnh chụp ảnh bên bảng nhiệt độ ngoài trời

- **Hành động:** người đang trả lời phỏng vấn
- **Ngữ cảnh:** lễ hội
- **Chi tiết hình ảnh:** chim màu tím, vật trang trí ở phía sau

Khi thực hiện semantic search, hệ thống ánh xạ toàn bộ truy vấn thành vector embedding. Tuy nhiên, do không có cơ chế tách riêng trọng số cho từng phần của truy vấn, hệ thống có xu hướng tập trung vào một vài từ khoá nổi bật hơn, dẫn đến:

- **Keyword “lễ hội”** rất phổ biến, dẫn đến hệ thống trả về nhiều khung hình có màu sắc rực rỡ, múa lân, phong nền hoa — nhưng thiếu nhân vật chính hoặc vật thể chim. 4.19a
- **Keyword “màu tím” hoặc “chim”** khiến kết quả thiên về các hình ảnh có màu tím phía sau nhân vật, nhưng không đủ để tạo thành ngữ cảnh đầy đủ như mô tả. 4.19b
- **Keyword “người phỏng vấn”** có thể trùng với nhiều chương trình phỏng vấn không thuộc lễ hội hoặc không có vật trang trí rõ ràng.


Do đó, với những truy vấn chứa nhiều chi tiết đồng thời như trên, hệ thống có thể đưa ra nhiều kết quả có **embedding tương đồng cao** nhưng không phải là

đáp án đúng. Cần kiểm tra kỹ các frame phía dưới top đầu để tìm được frame thỏa mãn toàn bộ điều kiện. Trong trường hợp này, khung hình đúng chứa đầy đủ cả:

- Người đàn ông đội nón trắng đang phỏng vấn
- Vật thể màu tím phía sau có hình dáng giống chim
- Bối cảnh rõ ràng là lễ hội hoa và văn hóa

Kết luận:

Hệ thống truy xuất ngữ nghĩa dựa trên embedding có thể gặp nhiều nếu các từ khoá trong truy vấn dẫn đến các phân cảnh phổ biến hoặc dễ gây hiểu sai. Trong các trường hợp như vậy, cần truy vấn kiểm chứng nhiều top-k để không bỏ sót.



(a) **Trường hợp 1 – Lễ hội:** Hệ thống trả về hình ảnh có phong nền lễ hội đặc trưng (màu sắc rực rỡ, trang trí), tuy nhiên thiếu chi tiết về chim mô hình màu tím.



(b) **Trường hợp 2 – Có người và màu tím:** Cảnh có người đang phỏng vấn phía sau có nhiều người màu tím, nhưng không rõ đây là chim hay vật trang trí theo ngữ cảnh truy vấn.



(c) **Trường hợp 3 – Khung hình chính xác:** người đang phỏng vấn, lễ hội phía sau, và vật trang trí có hình dáng giống chim màu tím.

Hình 4.19 So sánh các khung hình truy xuất theo từng mức độ phù hợp với truy vấn gốc

4.2.3 Truy vấn với cách diễn đạt khác so với truy vấn ban đầu

Câu truy cập thi cung cấp: “Trong một buổi trình diễn drone có biểu diễn một con gấu trúc trên bầu trời. Dàn drone này còn biểu diễn xếp thành một con số. Hỏi con số được biểu diễn là số bao nhiêu?”

Câu truy vấn sử dụng trong hệ thống: “Có một con số trên bầu trời”

- **Phương pháp truy xuất: Semantic Search (BEiT3 + FAISS)**
- **Mục tiêu:** Đánh giá khả năng của hệ thống trong việc truy xuất chính xác từ truy vấn ngắn gọn hơn, và kiểm tra khả năng truy xuất ngữ cảnh liên kề bằng kỹ thuật *Search Nearest Frame*.
- **Phân tích:**
 - Truy vấn ban đầu mô tả phức tạp với nhiều thông tin như “gấu trúc”, “drone”, “con số” khiến việc ánh xạ vector không tập trung.
 - Sau khi rút gọn truy vấn thành: “có một con số trên bầu trời”, hệ thống trả về chính xác khung hình tại giây 545 trong video L20_V002, hiển thị rõ con số “27” được tạo thành bởi đội hình drone 4.20.
 - Sau khi đã tìm được khung hình chính, hệ thống tiếp tục áp dụng chức năng **Search Nearest Frame** để truy xuất các khung hình kế cận. Kết quả trả về khung hình kế tiếp tại giây 554, nơi các drone xếp thành hình ảnh một con gấu trúc – đúng như yêu cầu trong truy vấn đề bài 4.21.

Kết luận: Kết hợp hai kỹ thuật **semantic search** và **neighbor frame retrieval** đã giúp hệ thống truy xuất không chỉ đúng khung hình chính (số “27”), mà còn mở rộng truy vấn đến các frame có liên quan như hình ảnh “gấu trúc”. Điều này chứng minh hiệu quả của hệ thống trong việc hỗ trợ truy vấn theo ngữ cảnh, kể cả khi truy vấn gốc mang tính tổng hợp và biểu tượng.

4.2.4 Truy vấn dài với chuỗi diễn tiến theo thời gian

Câu truy cập thi cung cấp: “Cảnh quay một tâm biến ghi ‘Tân Xuân Vạn Hạnh’ màu đỏ. Tiếp đó là một cô gái màu đỏ đang cầu nguyện rồi chuyển qua cảnh

Image Search

có một con số trên bầu trời



Q Find image by ID Results: 50 ▾

Video: L20_V002



ID: L20_V002_16... >
At 545s



ID: L20_V002_16... >
At 541s

Hình 4.20 Kết quả truy xuất từ truy vấn “có một con số trên bầu trời” – con số “27” được biểu diễn bởi dàn drone

cận những con chim sẻ.”

Câu truy vấn sử dụng trong hệ thống: “Một cô gái mặc đồ đỏ đi chùa”


- **Phương pháp truy xuất:** Semantic Search (BEiT3 + FAISS) kết hợp với kiểm tra thủ công khung hình lân cận bằng **Search Nearest**.
- **Mục tiêu:** Tìm một chuỗi khung hình phản ánh một diễn tiến thời gian gồm 3 giai đoạn: biển báo, cầu nguyện, chim sẻ.

Phân tích:

Trong truy vấn này, câu mô tả là một chuỗi các sự kiện xảy ra liên tiếp trong thời gian ngắn, trải qua nhiều frame. Khi sử dụng câu rút gọn “*một cô gái mặc đồ đỏ đi chùa*”, hệ thống semantic search trả về đúng khung hình chứa cô gái mặc áo dài đỏ đang đứng trước cây bonsai – bối cảnh quen thuộc của các ngôi chùa.

Tuy nhiên, để đánh giá chính xác tính đúng đắn của kết quả theo yêu cầu đề bài, cần kiểm tra:

- Có xuất hiện biển “Tân Xuân Vạn Hạnh” phía trước không?




Hình 4.21 Khung hình kế cận tìm được qua chức năng *Search Nearest*, cho thấy hình ảnh gấu trúc được tạo bởi dàn drone

- Cảnh sau có chứa chim sẻ như mô tả không?


Bằng cách sử dụng chức năng **search nearest frame** từ khung hình đã truy xuất được (frame chứa cô gái mặc đồ đỏ), hệ thống tìm thấy:

- **Các frame trước:** chứa biển tên “Tân Xuân Vạn Hạnh” màu vàng nền đỏ (ảnh 4.22c).
- **Các frame sau:** chứa cảnh chim sẻ đang đậu và bay trong sân chùa (ảnh 4.22c).


Điều này xác nhận rằng tuy chỉ dùng một truy vấn mô tả trung tâm, ta vẫn có thể kiểm tra và đối chiếu với toàn bộ ngữ cảnh nhờ vào việc xem xét khung hình liền kề.



(a) Tìm kiếm với một câu truy xuất đặc trưng nhất



(b) Lựa chọn frame ảnh tình nghi cao nhất



(c) Dùng tìm kiếm lân cận để kiểm tra thỏa yêu cầu

Hình 4.22 Quy trình truy xuất khung hình trong thời gian dài

Kết luận:

Trong các truy vấn dài chứa nhiều hành động xảy ra tuần tự theo thời gian, việc chỉ dùng một truy vấn ngắn là chưa đủ để đảm bảo truy xuất chính xác toàn bộ ngữ nghĩa. Tuy nhiên, bằng cách kết hợp semantic search với **tìm kiếm khung hình liên kề (nearest search)**, hệ thống có thể hỗ trợ xác minh và tái cấu trúc diễn tiến truy vấn một cách hiệu quả.


4.2.5 Truy vấn bằng OCR khi thiếu mô tả rõ ràng

Một số câu hỏi trong đề bài không cung cấp đầy đủ ngữ cảnh hình ảnh hoặc diễn giải đầy đủ câu truy vấn, mà chỉ đề cập tới một từ khóa có thể xuất hiện trong ảnh — ví dụ như “terminal” hoặc một phần của nó là “termi”.


Ví dụ tình huống: Đề bài yêu cầu xác định vị trí có liên quan đến TERMI (chưa hiển thị toàn bộ chữ) ở trên khung hình. Với truy vấn ngữ nghĩa, hệ thống không thể ánh xạ nội dung ngắn như vậy, đặc biệt khi từ khóa không nằm trong khung mô tả văn bản mà xuất hiện trực tiếp trên biển hiệu hoặc bảng thông tin.

Giải pháp: Sử dụng tính năng **Text in Image Search (OCR-Based Search)** để tìm các frame có chứa từ được trích xuất bằng công nghệ nhận diện ký tự quang học (OCR). Cơ chế tìm kiếm hỗ trợ cả *so khớp không hoàn chỉnh (fuzzy match)* nên có thể tìm thấy frame chứa từ khóa một phần.

Kết quả minh họa:



Hình 4.23 Tính năng OCR-Based Search với truy vấn từ khóa “termi”



Hình 4.24 Hệ thống trả về frame có dòng chữ “termi” đúng vị trí cần truy xuất

Phân tích:

- Trong trường hợp này, mô hình OCR (DeepSolo + PARSeq) đã phát hiện dòng chữ TERMI, lưu vào cơ sở dữ liệu text dạng MongoDB Atlas.
- Khi người dùng nhập từ khoá “termi”, hệ thống sử dụng fuzzy search để tìm khớp một phần và trả về đúng khung hình chứa chữ cần truy xuất.
- Đây là phương pháp đặc biệt hữu ích với các câu hỏi không đủ ngữ nghĩa hoặc yêu cầu truy xuất dựa trên bảng hiệu, tên địa điểm, hoặc các chi tiết ký tự cụ thể trong ảnh.

Kết luận: Tính năng **OCR-Based Search** đóng vai trò hỗ trợ quan trọng cho các truy vấn “thiếu dữ kiện”, hoặc các truy vấn yêu cầu tìm từ khoá trực tiếp trên hình ảnh — đặc biệt khi các từ khoá không thể ánh xạ ngữ nghĩa bằng embedding.

Chương 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

4.3 Kết luận chung

Trong khuôn khổ đề tài, hệ thống truy xuất video theo truy vấn ngôn ngữ tự nhiên đã được thiết kế, triển khai và thử nghiệm thành công trên bộ dữ liệu thực tế từ cuộc thi **AI Challenge TP. Hồ Chí Minh**. Hệ thống được xây dựng dựa trên các thành phần chính như: nhúng ngữ nghĩa (semantic embedding), tìm kiếm lân cận theo thời gian (neighbor frame search), phát hiện đối tượng (YOLOv8), nhận diện văn bản (DeepSolo + PARSeq) và lưu trữ/tra cứu dữ liệu sử dụng FAISS và MongoDB.

Các kết quả thu được cho thấy hệ thống có khả năng đáp ứng linh hoạt và hiệu quả nhiều loại truy vấn khác nhau, cụ thể:

- **Truy vấn cụ thể, rõ ràng:** Hệ thống hoạt động tốt với các mô tả ngắn có yếu tố dễ nhận diện (ví dụ: bảng nhiệt độ, hành động chụp hình), trả về khung hình phù hợp ngay trong top đầu.
- **Truy vấn dài, nhiều thành phần:** Với truy vấn phức tạp, hệ thống kết hợp semantic embedding với tìm kiếm khung hình lân cận để vẫn xác định chính xác sự kiện được mô tả.
- **Truy vấn rút gọn:** Truy vấn dạng khái quát (ví dụ “một con số trên bầu trời”) vẫn cho kết quả chính xác nhờ khả năng mở rộng ngữ nghĩa từ khung hình đến chuỗi frame liên quan.
- **Truy vấn theo chuỗi thời gian:** Hệ thống hỗ trợ tốt truy vấn yêu cầu theo dõi một trình tự các hành động, bằng cách dò tìm khung hình lân cận và kiểm tra logic thời gian.
- **Truy vấn văn bản trong ảnh (OCR):** Hệ thống nhận diện chính xác các từ khóa ngắn xuất hiện trong ảnh, nhờ sự kết hợp giữa phát hiện (DeepSolo), nhận dạng (PARSeq) và truy vấn mờ (fuzzy query) trên MongoDB.

Kết quả chấm điểm qua ba vòng thi là **13.0**, **20.8** và **27.8**, với tổng điểm **61.6** và điểm tham khảo đạt **64.8**. Những kết quả này không chỉ thể hiện năng lực ổn

định của hệ thống, mà còn chứng minh khả năng truy xuất ngữ nghĩa và tổng quát hóa trong môi trường dữ liệu thực tế.

4.3.0.1 So sánh với mục tiêu ban đầu: Đối chiếu với các mục tiêu nghiên cứu đề ra trong Chương 1, có thể thấy hệ thống đã đạt được phần lớn kỳ vọng ban đầu:

- Mục tiêu phát triển hệ thống truy xuất hiệu quả, thân thiện người dùng đã được hiện thực hóa qua giao diện web tích hợp nhiều phương thức truy vấn.
- Mục tiêu thu hẹp khoảng cách ngữ nghĩa giữa truy vấn và nội dung video đã được giải quyết bước đầu nhờ các mô hình ngôn ngữ–thị giác (BEiT3, CLIP) và mở rộng kết quả thông qua tìm kiếm khung hình lân cận.
- Việc tích hợp OCR, phát hiện đối tượng, và tìm kiếm vector cho thấy khả năng mở rộng đa phương thức — hướng đến giải quyết các bài toán truy vấn phức tạp trong tương lai.

4.4 Hạn chế

Bên cạnh những kết quả khả quan, hệ thống vẫn còn một số hạn chế nhất định:

- **Phân tách ngữ nghĩa chưa rõ ràng:** Chưa bóc tách được các yếu tố thành phần trong truy vấn (hành động, đối tượng, ngữ cảnh), khiến embedding có thể bị “nhiều” hoặc không tập trung.
- **Thiếu truy vấn phối hợp:** Các truy vấn kết hợp (ví dụ: hành động + văn bản + đối tượng) chưa được hỗ trợ đầy đủ, do các mô-đun (semantic, OCR, detection) chưa tích hợp cùng nhau.
- **Độ trễ MongoDB:** Truy vấn từ MongoDB Atlas còn chậm với lượng dữ liệu lớn, do chưa có tối ưu hóa chỉ mục hoặc cache nội bộ.
- **Chưa tự động hóa toàn bộ pipeline:** Việc kiểm tra kết quả mở rộng bằng khung hình lân cận vẫn thủ công, chưa xây dựng thành luồng xử lý hoàn chỉnh.

4.5 Hướng phát triển

Để cải thiện hiệu năng và mở rộng tính ứng dụng thực tế, đề tài có thể phát triển theo các hướng sau:

- **Tách truy vấn thành phần:** Sử dụng kỹ thuật NLP để bóc tách truy vấn thành các phần (động từ, danh từ, ngữ cảnh...) và định tuyến chúng đến các mô-đun xử lý tương ứng.
- **Truy vấn đa chế độ (multi-modal):** Cho phép người dùng nhập các truy vấn tích hợp (văn bản + hình ảnh + đối tượng), kết hợp kết quả từ các mô hình như CLIP + OCR + YOLOv8.
- **Tối ưu MongoDB:** Áp dụng indexing tổng hợp nhiều trường, truy vấn `$text` + `$in` + `$and`, caching theo session và lọc sơ bộ để giảm tải hệ thống và tăng tốc độ phản hồi.
- **Tự động kiểm tra khung hình lân cận:** Xây dựng mô-đun phân tích frame lân cận theo thời gian, dùng FAISS hoặc cosine similarity để phát hiện các frame bổ sung theo chuỗi.
- **Mở rộng ứng dụng thực tế:** Tích hợp hệ thống vào các bài toán như tra cứu nội dung tin tức, bài giảng, giám sát hình ảnh camera thông minh, hoặc thư viện video giáo dục dựa trên truy vấn tự nhiên.

Tổng kết: Đề tài đã hoàn thành toàn diện các mục tiêu đặt ra: xây dựng hệ thống truy xuất video dựa trên ngữ nghĩa, tích hợp nhiều phương thức (semantic, OCR, object detection), và đạt hiệu suất ổn định trong môi trường dữ liệu thực tế. Với những hướng phát triển được đề xuất, hệ thống hoàn toàn có tiềm năng ứng dụng ở quy mô lớn, trong các hệ thống tìm kiếm video thông minh và thân thiện người dùng.

TÀI LIỆU THAM KHẢO

- [1] L. Vadicamo, R. Arnold, W. Bailer, F. Carrara, C. Gurrin, N. Hezel, X. Li, J. Lokoc, S. Lubos, Z. Ma, *et al.*, “Evaluating performance and trends in interactive video retrieval: Insights from the 12th vbs competition,” *IEEE Access*, 2024.
- [2] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, *et al.*, “Learning transferable visual models from natural language supervision,” in *International conference on machine learning*, pp. 8748–8763, PMLR, 2021.
- [3] W. Wang, H. Bao, L. Dong, J. Bjorck, Z. Peng, Q. Liu, K. Aggarwal, O. K. Mohammed, S. Singhal, S. Som, *et al.*, “Image as a foreign language: Beit pretraining for all vision and vision-language tasks,” *arXiv preprint arXiv:2208.10442*, 2022.
- [4] M. Ye, J. Zhang, S. Zhao, J. Liu, T. Liu, B. Du, and D. Tao, “Deepsolo: Let transformer decoder with explicit points solo for text spotting,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 19348–19357, 2023.
- [5] D. Bautista and R. Atienza, “Scene text recognition with permuted autoregressive sequence models,” in *European conference on computer vision*, pp. 178–196, Springer, 2022.
- [6] M. Douze, A. Guzhva, C. Deng, J. Johnson, G. Szilvasy, P.-E. Mazaré, M. Lomeli, L. Hosseini, and H. Jégou, “The faiss library,” *arXiv preprint arXiv:2401.08281*, 2024.
- [7] T. Soucek and J. Lokoc, “Transnet v2: An effective deep network architecture for fast shot transition detection,” in *Proceedings of the 32nd ACM International Conference on Multimedia*, pp. 11218–11221, 2024.